ПЗ 2

1. Рассмотрим выборку из 4 точек наблюдений двух признаков: 1 - количество прогульщиков по группе за 1 семестр, 2 - количество прогульщиков по группе за 2 семестр, где каждая точка описывает одну группу.

$x_1 = (7\ 6)$

$x_2 = (8\ 12)$

$x_3 = (15\ 17)$

$x_4 = (3\ 5)$

2. Формируем матрицу данных X:

$$X = \begin{pmatrix} 7 & 6 \\ 8 & 12 \\ 15 & 17 \\ 3 & 5 \end{pmatrix}$$

3. По объему наблюдений находим вектор средних значений

$$\mu = \frac{1}{4}\left((7\ 6)^T + (8\ 12)^T + (15\ 17)^T + (3\ 5)^T \right) = (8{,}25\ 10)^T$$

4. Вычисляем матрицу центрированных данных.

$$B = \begin{pmatrix} 7 & 6 \\ 8 & 12 \\ 15 & 17 \\ 3 & 5 \end{pmatrix} - \begin{pmatrix} 1 \\ 1 \\ 1 \\ 1 \end{pmatrix} (8{,}25\ 10) = \begin{pmatrix} 7 & 6 \\ 8 & 12 \\ 15 & 17 \\ 3 & 5 \end{pmatrix} - \begin{pmatrix} 8{,}25 & 10 \\ 8{,}25 & 10 \\ 8{,}25 & 10 \\ 8{,}25 & 10 \end{pmatrix} =$$

$$= \begin{pmatrix} -1{,}25 & -4 \\ -0.25 & 2 \\ 6.75 & 7 \\ -5.25 & -5 \end{pmatrix}$$

5. Вычислим ковариационную матрицу

$$C = \frac{1}{3}\begin{pmatrix} -1.25 & -0.25 & 6.75 & -5.25 \\ -4 & 2 & 7 & -5 \end{pmatrix}\begin{pmatrix} -1.25 & -4 \\ -0.25 & 2 \\ 6.75 & 7 \\ -5.25 & -5 \end{pmatrix} =$$

$$= \frac{1}{3}\begin{pmatrix} (-1.25)^2 + (-0.25)^2 + (6.75)^2 + (-5.25)^2 & -1.25\cdot(-4) + (-0.25)\cdot 2 + 6.75\cdot 7 + (-5.25)5 \\ -4(-1.25) + 2(-0.25) + 7(6.75) + (-5)(-5.25) & (-4)^2 + 2^2 + 7^2 + (-5)^2 \end{pmatrix}$$

$$= \begin{pmatrix} \frac{299}{12} & 26 \\ 26 & \frac{94}{3} \end{pmatrix} = \begin{pmatrix} 24.92 & 26 \\ 26 & 31.33 \end{pmatrix}$$

6. Вычислим детерминант и ранг ковариационной м-цы при использовании QR-разложение методом Гивенса, в качестве машинного нуля $\varepsilon = 0.01$

$Q = E$

Мы хотим зануллить элемент 2,1 и привести матрицу к верхнетреугольному виду

$$\sin\theta = \frac{26}{\sqrt{26^2 + \left(\frac{299}{12}\right)^2}} = \frac{26}{36.01} = 0.72$$

$$\cos\theta = \frac{\frac{299}{12}}{\sqrt{26^2 + \left(\frac{299}{12}\right)^2}} = \frac{24.92}{36.01} = 0.69$$

$$\Rightarrow G_{21}^T = \begin{pmatrix} 0.69 & 0.72 \\ -0.72 & 0.69 \end{pmatrix}$$

$$C' = \begin{pmatrix} 0.69 & 0.72 \\ -0.72 & 0.69 \end{pmatrix}\begin{pmatrix} 24.92 & 26 \\ 26 & 31.33 \end{pmatrix} = \begin{pmatrix} 0.69\cdot 24.92 + 0.72\cdot 26 & 0.69\cdot 26 + 0.72\cdot 31.33 \\ -0.72\cdot 24.92 + 0.69\cdot 26 & -0.72\cdot 26 + 0.69\cdot 31.33 \end{pmatrix} =$$

$$= \begin{pmatrix} 35.91 & 40.50 \\ -0.0024 & 2.90 \end{pmatrix} = \begin{pmatrix} 35.91 & 40.50 \\ 0.00 & 2.90 \end{pmatrix}$$

принимаем за 0

$$Q = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}\begin{pmatrix} 0.69 & -0.72 \\ 0.72 & 0.69 \end{pmatrix} = \begin{pmatrix} 0.69 & -0.72 \\ 0.72 & 0.69 \end{pmatrix}$$

$$\Rightarrow \quad C \approx \begin{pmatrix} 0.69 & -0.72 \\ 0.72 & 0.69 \end{pmatrix} \begin{pmatrix} 35.91 & 40.50 \\ 0.00 & 2.90 \end{pmatrix}$$

По исходным данным можно заметить отсутствие линейной зависимости количества пропусков в 1 семестре от количества пропусков во 2 семестре. Положительные недиагональные элементы матрицы C, указывают на то, что кол-во пропусков в 1 и во 2 семестрах растут совместно.

QR-разложение позволяет установить независимость признаков. Ранг матрицы R равен 2, значит данные нельзя точно описать в пространстве меньшей размерности. Анализ данных выполняется с некоторым порогом, который принимается за машинный ноль. $rk\, C = 2$ $\det C = \det Q \cdot \det R$, поскольку матрица Q - ортогональна, то её определитель ± 1, в данном конкретном случае в силу работы с приближенными значениями в рамках машинного нуля $\det Q = 0.9945 \approx 1 \Rightarrow \det C \approx \det R = 104.14$

7. Проиллюстрируем поведение ранга и детерминанта ковариационной матрицы:

1) Все p признаков независимы

В этом случае ранг соответствующей ковариационной матрицы совпадает с количеством всех линейно независимых p признаков $rk\, C = p$, при этом в силу этого определитель соответствующей матрицы отличен от нуля $\det C > 0$.

2) Некоторые признаки лежат в одной гиперплоскости

В этом случае определитель соответствующей матрицы

становится равным нулю, поскольку детерминант ковариационной матрицы пропорционален объему p-мерного пространства рассеяния данных, который становится равным нулю, благодаря линейной зависимости трех данных расположенных в одной плоскости.
$\det C = 0 \quad rk\, C < p$

3) Признаков больше чем наблюдений

В этом случае признаки являются линейно зависимыми. Поскольку при наличии p признаков и n наблюдений, где $p > n$, линейно независимыми могут быть не более чем $n-1$ признаков, в результате операции центрирования $\det C = 0$, $rk\, C \leq n-1 < p$.

8. Можно ли для решения данной задачи применить LU-разложение или разложение Холецкого?

1. LU-разложение возможно использовать для решения данной задачи, однако данный метод имеет ряд недостатков относительно QR разложения:

1) Для LU-разложения требуется неравенство главных миноров нулю, что QR-разложение не требует.

2) $\det C = \det L \cdot \det U$, поскольку L - нижнетреугольная матрица с единицами на диагонали, то $\det C = \det U$, также $rk\, C = rk\, U$

3) LU-разложение является менее устойчивым чем QR: сильнее накапливает ошибки, поскольку QR-разложение в отличии от LU используют ортогональные преобразо-

вания $\|Qx\| = \|x\|$

2. Разложение Холецкого также может быть использовано для решения данной задачи, однако требует более строгого условия в виде SPD матрицы.

$\det C = \det L^2$

$\operatorname{rk} C = \operatorname{rk} L$

При этом разложение Холецкого по уровню устойчивости ближе к QR, чем LU-разложение.